Предлагаем вам выполнить итоговое задание по модулю с целью закрепления полученных знаний и отработки навыка разработки DWH. Именно умение работать с хранилищами данных повышает вас на уровень middle и даёт возможность выполнять функции не только системного аналитика, но и аналитика DWH или системного аналитика DWH.

Какие задачи вам предстоит решить:

- проектирование структуры хранилища данных (логической модели DWH)
- подготовка технических спецификаций
- проектирование ETL-процессов
- формулирование бизнес-правил в соответствии с принципами Data Quality

Удачи в выполнении задания!

Контекст

Добро пожаловать в онлайн-университет “Учиться легко!”

На сайте онлайн-университета любой пользователь старше 18 лет может приобрести один или несколько курсов из предложенных в каталоге. Чтобы приобрести курс, ему необходимо зарегистрироваться на сайте, указав электронную почту и номер телефона, выбрать курс и произвести полную оплату (*). Такое событие в системе онлайн-университета будет отражено как “Услуга”, а пользователь становится студентом. Стоит заметить, что курс закреплен только за одним преподавателем (**).

(*) Услуга может быть только оплаченной 100% за каждый выбранный курс.

(**) В данном случае будем считать, что преподаватели не могут замещать друг друга.

Руководителю онлайн-университета необходимо знать, сколько услуг и какая выручка была по каждому курсу и направлению в месяц с целью анализа, какой курс и направление стали наиболее популярными.

Данные о всех пользователях (то есть студентах и преподавателях) формируются в Auth системе (системе авторизации

пользователей) в виде таблицы «Пользователи».
Данные об услугах и курсах формируются в CRM системе в виде соответствующих таблиц «Услуги» и «Курсы». А данные об оплатах формируются в Billing системе (системе обработки платежей) соответственно в таблице “Оплаты”.

Примеры таблиц представлены ниже.

Таблица “Пользователи”- Система-источник “Auth”

Код пользователя	Дата и время регистрации	ФИО	Телефон	Email	Тип пользователя
1	2019-01-23 16:15:00	Alan Dominguez	123-456-789	alan@gmail.com	Студент
2	2020-05-02 20:32:00	Chuck Clark		chuckclark@gmail.com	Преподаватель
3	2021-03-19 08:57:00	George Bell	555-666-777	bell@gmail.com	Студент
…	…	…	…	…	…

Таблица “Курсы”- Система-источник “CRM”

Код курса	Наименование курса	Стоимость	Наименование направления	Описание направления	Код преподавателя
111	Тестировщик ПО	100	Программирование	IT-профессии с углубленным знанием различных языков программирования	2
112	Python-разработчик с нуля	238	Программирование	IT-профессии с углубленным знанием различных языков программирования	39
211	Бухгалтер	1873	Финансы и инвестиции	Профессии, связанные с финансовой областью	10
114	Frontend-разработчик с нуля	11199	Программирование	IT-профессии с углубленным знанием различных языков программирования	84
…	…	…	…	…	…

Таблица “Услуги”- Система-источник “CRM”

Код услуги	Дата и время создания услуги	Код студента	Код курса
CA-120775	2019-01-25 08:23:00	1	111
CA-120775	2019-01-25 08:23:00	1	112
US-949596	2020-05-10 12:15:00	5	211
RU-348826	2021-03-19 10:11:00	3	114
…	…	…	…

Таблица “Оплаты”- Система-источник “Billing”

Код оплаты	Код услуги	Код студента	Дата и время создания оплаты	Сумма оплаты
243	CA-120775	1	2019-01-25 08:23:00	338
358	US-949596	5	2020-05-10 12:15:00	1873

Код оплаты	Код услуги	Код студента	Дата и время создания оплаты	Сумма оплаты
…	…	…	…	…

Задание

1. Сформируйте логические модели данных (*) Core Data Layer и Data Mart Layer
2. Подготовьте три технические спецификации: Primary Data Layer, Core Data Layer и Data Mart Layer (по аналогии с домашним заданием №2)
3. Постройте схему ETL-процесса на базе технических спецификаций Raw Data Layer, Core Data Layer и Data Mart Layer, сформированных в п.2
4. Опишите не менее 3 бизнес-правил и сформируйте метрики для одной сущности на выбор на базе ключевых критериев качества данных, а также установите для каждой метрики целевой уровень

(*) На уровне Core Data Layer необходимо выделить сущности “Студент” и “Преподаватель” (сущность “Пользователи” следует опустить).

Рекомендуемые инструменты: любой инструмент для построения схемы.

Формат сдачи работы

Прикрепите в личном кабинете готовое решение в виде файла в формате pdf или Google таблицы с учётом всех необходимых схем/диаграмм. Не забудьте открыть доступ на просмотр и комментирование.

Критерии оценивания

По итогу выполнения задания вы получите зачёт.

Задание считается **выполненным**, если:

- выполнены все пункты задания
- верно выделены ключевые сущности системы и определены связи между ними
- сформированы логические модели данных Core Data Layer и Data Mart Layer
- разработаны три технические спецификации: Primary Data Layer, Core Data Layer и Data Mart Layer
- построена схема ETL процесса от Source Systems до Data Mart Layer
- описано не менее 3 критериев качества данных, бизнес-правил и метрик с указанием целевого уровня для одной любой сущности

Задание будет отправлено **на доработку**, если:

- не выполнен хотя бы один пункт поставленного задания
- выделены не все ключевые сущности системы и/или есть ошибки в связях между ними
- отсутствуют логические модели данных Core Data Layer и Data Mart Layer и/или технические спецификации: Primary Data Layer, Core Data Layer и Data Mart Layer
- в схеме ETL процесса неверно указаны связи между слоями и/или объектами DWH
- описано менее 3 бизнес-правил и соответствующих метрик для одной любой сущности DWH